Perfiles ciudadanos de participación electoral en México, 2009–2024: una segmentación de datos agregados

Hackea la Participación: Datos que construyen democracia · Reto 1: Perfiles ciudadanos de participación

Equipo: [nombre del equipo] · **Integrantes:** [Integrante 1; Integrante 2; …]

Repositorio de código: [URL del repositorio] · Octubre de 2026

Presupuesto de cuartillas (total objetivo: 11.5 de un máximo de 12)

Las bases piden 8 a 12 cuartillas con Arial/Calibri 11 e interlineado 1.5. Esta plantilla cumple ese formato; lo que debes vigilar es el largo. Presupuesto sugerido (incluye figuras y tablas):

Resumen ejecutivo	0.5	Estrategias diferenciadas	1.25
1. Introducción	0.75	7. Limitaciones y ética	0.5
2. Datos	1.0	8. Conclusiones	0.5
3. Metodología	2.25	Referencias	0.5
4. Resultados de la segmentación	1.25	**Total**	**11.5**
5. Perfiles ciudadanos (4 a 6)	3.0		

Las partes en rojo [PENDIENTE: …] son las que debes redactar o confirmar. La Sección 3 ya viene redactada porque describe el código del proyecto: revísala y ajusta los parámetros que cambies. Con `\guiafalse` desaparecen todas estas cajas.

Resumen ejecutivo

Guía

Máximo 180 palabras, sin referencias. Cuatro ideas en este orden: (1) problema y pregunta guía; (2) datos y método en una frase; (3) los hallazgos: cuántos perfiles, cuál es el más grande, cuál el de mayor oportunidad; (4) qué puede hacer el INE con esto. Escríbelo *al final*, cuando ya tengas los resultados.

[**PENDIENTE:** Resumen de 150–180 palabras: problema, datos y método, hallazgos principales (número de perfiles y su peso), implicación para el diseño de campañas.]

1. Introducción

Guía

Pregunta guía de las bases: *¿Qué tipos de ciudadanía existen según su comportamiento de participación?* Utilidad para el INE: diseño de campañas focalizadas y mensajes diferenciados por perfil. Cierra con una frase que anuncie la estructura del documento.

La participación electoral no es homogénea: varía con la edad, el sexo, el territorio y el tipo de elección. Este documento responde a la pregunta *¿qué tipos de ciudadanía existen según su comportamiento de participación?* mediante una segmentación (clustering) de los datos agregados

de los Conteos Censales de Participación Ciudadana (CCPC) 2009–2024 del Instituto Nacional Electoral [1], con el propósito de apoyar campañas focalizadas y mensajes diferenciados por perfil [2].

[**PENDIENTE:** Párrafo de contexto (1–2 frases): por qué importa distinguir perfiles; dato o cita que motive el problema.]

Objetivo. Identificar entre 4 y 6 perfiles ciudadanos claramente diferenciados, caracterizarlos con edad, sexo, tipo de sección, región e historial de participación, y proponer una estrategia de fomento a la participación para cada uno.

Aportación. [**PENDIENTE:** 2–3 frases: qué aporta su análisis frente a mirar promedios nacionales (p. ej. perfiles que se pierden en el promedio, brecha entre elecciones presidenciales e intermedias).]

Organización. La Sección 2 describe los datos; la 3, la metodología; la 4, la selección del número de perfiles; la 5, los perfiles; la 6, las estrategias; y las secciones 7 y 8 cierran con limitaciones y conclusiones.

2. Datos

Guía

Describe la fuente con precisión y sin exagerar. Reporta números concretos tomados de la salida del notebook 01 y 02 (filas, segmentos, descartes). Debe quedar claro que *solo se usaron datos agregados, sin datos personales*, como piden las bases.

2.1 Fuente y cobertura

Se utilizaron los datos agregados de la Plataforma CCPC 2009–2024 [1], que integra las bases censales de participación de las elecciones federales de 2009, 2012, 2015, 2018, 2021 y 2024 y permite consultarlas a distintos niveles territoriales [3]. [**PENDIENTE:** Confirmar con la documentación del INE: cómo se construye la base (marca de participación en listas nominales), niveles de desagregación disponibles y fecha de descarga.] No se emplearon datos personales.

2.2 Variables

[**PENDIENTE:** Listar las variables realmente usadas tras revisar el archivo descargado: elección, entidad, distrito, tipo de sección, sexo, grupo de edad, lista nominal y participantes. Indicar si la escolaridad está disponible; si no, decirlo explícitamente.]

2.3 Calidad y tratamiento

[**PENDIENTE:** Reportar con números: filas iniciales y finales; porcentaje descartado por cada regla (nulos, lista nominal ≤ 0, participantes $>$ lista nominal); segmentos finales; celdas imputadas (ver salidas de los notebooks 01 y 02).]

3. Metodología

Guía

Esta sección ya está escrita a partir del código (notebooks 02 y 03). Revisa los parámetros en rojo y cámbialos si modificaste algo. Conserva la subsección de *falacia ecológica*: suma rigor.

3.1 Unidad de análisis y variables

La unidad de análisis es un *segmento* $s = (\text{entidad}, \text{distrito}, \text{tipo de sección}, \text{sexo}, \text{grupo de edad})$. Para cada segmento s y elección $e \in \{2009, 2012, 2015, 2018, 2021, 2024\}$ se calculó la tasa de participación

$$\tau_{s,e} = \frac{P_{s,e}}{L_{s,e}}, \tag{1}$$

donde $P_{s,e}$ son las personas que participaron y $L_{s,e}$ la lista nominal del segmento. Las tasas nacionales y por grupo se obtienen sumando numeradores y denominadores, no promediando tasas. El vector $(\tau_{s,2009}, \ldots, \tau_{s,2024})$ es el *historial de participación* del segmento y constituye el único insumo del clustering; edad, sexo, tipo de sección y región se reservan para caracterizar los grupos, de modo que los perfiles emerjan del comportamiento y no de la demografía.

Para interpretar los perfiles se derivaron tres indicadores. Sean $\mathcal{P}$ y $\mathcal{I}$ las elecciones presidenciales (2012, 2018, 2024) e intermedias (2009, 2015, 2021). La *brecha presidencial–intermedia* es

$$B_s = \frac{1}{|\mathcal{P}|} \sum_{e \in \mathcal{P}} \tau_{s,e} - \frac{1}{|\mathcal{I}|} \sum_{e \in \mathcal{I}} \tau_{s,e}, \tag{2}$$

la *volatilidad* es la desviación estándar de las seis tasas y la *tendencia* es la pendiente β_s de la regresión lineal de $\tau_{s,e}$ sobre el índice de elección $t = 1, \ldots, 6$ (pp por elección).

3.2 Preprocesamiento

Se descartaron los segmentos con lista nominal media menor a [**PENDIENTE:** 30] personas, porque sus tasas son ruido muestral. Se toleraron hasta [**PENDIENTE:** 2] elecciones sin dato por segmento; las faltantes se imputaron con la mediana del mismo grupo de edad y sexo. Las seis

tasas se estandarizaron (puntaje z)

$$z_{s,e} = \frac{\tau_{s,e} - \mu_e}{\sigma_e}, \tag{3}$$

para que ninguna elección domine por escala.

3.3 Algoritmo de segmentación

Se empleó k-means ponderado [4, 5], que minimiza

$$\sum_s w_s \, \|\mathbf{z}_s - \mathbf{c}_{g(s)}\|^2, \qquad w_s \propto \sqrt{\bar{L}_s}, \tag{4}$$

con $\bar{L}_s$ la lista nominal media del segmento y $g(s)$ su grupo. La raíz cuadrada evita que unos pocos segmentos muy grandes dominen (un segmento de 1,600 personas pesa el doble, no cuatro veces, que uno de 400). Se eligió k-means por su interpretabilidad (cada centroide es una trayectoria de participación) y escalabilidad; se utilizaron 50 inicializaciones aleatorias y semilla fija (42), y los grupos se reordenaron por participación media creciente. Para verificar robustez se contrastó con mezclas gaussianas [7] y con agrupamiento jerárquico de Ward [6] sobre una submuestra de [**PENDIENTE:** 5,000] segmentos.

3.4 Selección del número de perfiles y validación

Las bases piden entre 4 y 6 perfiles. Se evaluaron $k = 2, \ldots, 10$ con la silueta [8], el índice de Calinski–Harabasz [9], el de Davies–Bouldin [10], el BIC de la mezcla gaussiana [7] y el tamaño del grupo menor (un grupo con menos de ≈1% de los segmentos suele ser ruido). La *estabilidad* se estimó con [**PENDIENTE:** 20] submuestras aleatorias del 80% de los segmentos: en cada una se ajustó el modelo, se asignó a todos los segmentos y se comparó cada par de particiones con el índice de Rand ajustado (ARI) [11]; un ARI promedio cercano a 1 indica que los grupos se reproducen [12]. Entre los $k \in \{4, 5, 6\}$ con ARI promedio ≥ 0.8 se tomó el de mayor silueta como punto de partida, y la decisión final incorporó la interpretabilidad de los perfiles. [**PENDIENTE:** Indicar el k elegido y la razón, en una frase.]

3.5 Caracterización, nombre de los perfiles y reproducibilidad

Las medias de cada perfil se ponderaron por tamaño del segmento. La composición se resume con un índice

$$I_{g,c} = \frac{p_{g,c}}{p_c} \times 100, \tag{5}$$

donde $p_{g,c}$ es el porcentaje de la lista nominal del perfil g en la categoría c y p_c el de toda la base; $I = 150$ significa que la categoría está sobrerrepresentada 1.5 veces. Los nombres de los perfiles son narrativos y se apoyan en nivel de participación, brecha presidencial–intermedia y tendencia. El análisis se implementó en Python con scikit-learn [14]; el código y los datos derivados están en [URL del repositorio].

3.6 Falacia ecológica

Los datos son agregados: los perfiles describen *segmentos* (territorio $\times$ sexo $\times$ edad), no personas. Inferir que cada individuo de un segmento se comporta como el segmento incurre en la falacia ecológica [13]. Además, el grupo de edad "20–24" de 2009 no está formado por las mismas personas que el de 2024; el historial describe el comportamiento típico del segmento en cada elección, no trayectorias individuales.

4. Resultados de la segmentación

Guía

Presenta (a) la tabla de métricas, (b) la justificación de k y (c) la vista general de los perfiles con la figura de trayectorias. Tabla y figuras se llenan solas tras correr los notebooks y `generar_tablas_latex.py`. Las filas sombreadas son el rango permitido (4–6).

4.1 Elección del número de perfiles

La Tabla 1 resume los criterios de selección. [**PENDIENTE:** Interpretar en 4–6 líneas: qué k gana en cada criterio, estabilidad, tamaño mínimo de grupo y por qué se eligió el k final; si hay conflicto entre métricas, decirlo.]

[**PENDIENTE:** tabla `tabla_k.tex`; ejecuta generar_tablas_latex.py]

Tabla 1: Criterios de selección de k (C-H: Calinski–Harabasz; D-B: Davies–Bouldin; ARI boot.: estabilidad por submuestreo). Filas sombreadas: rango pedido en las bases.

4.2 Vista general de los perfiles

[**PENDIENTE:** 2–3 frases: cuántos perfiles, cuánto pesa cada uno en la lista nominal y qué los separa más (nivel general, selectividad presidencial, tendencia).]

[**PENDIENTE:** figura `trayectorias_perfiles.png`; corre los notebooks]

Figura 1: Trayectoria de participación de cada perfil frente al promedio de la base (franjas: elecciones presidenciales).

5. Perfiles ciudadanos

Guía

Un bloque por perfil (el número depende de tu k: 4 a 6; borra o copia bloques). Cada bloque debe responder, en 6–9 líneas: **quién** es (edad, sexo, tipo de sección, región, con los índices de composición del notebook 04); **cómo participa** (nivel, patrón presidencial/intermedia, tendencia); **qué lo distingue** de los demás. El nombre debe ser narrativo y respetuoso ("Los constantes", no "Los apáticos"). Reemplaza la ficha preliminar por tu infografía final si ya la tienes. Ejemplo de lectura de un índice: edad "Jóvenes" con $I = 150 \Rightarrow$ 1.5 veces más jóvenes que el promedio.

[**PENDIENTE:** Introducción de 2 líneas a la sección: cómo leer los indicadores de cada perfil (brecha en puntos porcentuales; tendencia en pp por elección).]

5.1 Perfil 0: [PENDIENTE: nombre narrativo]

% de la lista nominal	Participación media (%)	Brecha pres.–interm. (pp)	Tendencia (pp/elección)	Volatilidad (pp)
[**PENDIENTE:** 0/pct]	[**PENDIENTE:** 0/media]	[**PENDIENTE:** 0/brecha]	[**PENDIENTE:** 0/tend]	[**PENDIENTE:** 0/vol]

[**PENDIENTE:** Quién es / cómo participa / qué lo distingue (6–9 líneas).]

[**PENDIENTE:** figura `ficha_perfil_0.png`; corre los notebooks]

Figura 2: Ficha preliminar del perfil 0.

5.2 Perfil 1: [PENDIENTE: nombre narrativo]

% de la lista nominal	Participación media (%)	Brecha pres.–interm. (pp)	Tendencia (pp/elección)	Volatilidad (pp)
[**PENDIENTE:** 1/pct]	[**PENDIENTE:** 1/media]	[**PENDIENTE:** 1/brecha]	[**PENDIENTE:** 1/tend]	[**PENDIENTE:** 1/vol]

[**PENDIENTE:** Quién es / cómo participa / qué lo distingue (6–9 líneas).]

5.3 Perfil 2: [PENDIENTE: nombre narrativo]

% de la lista nominal	Participación media (%)	Brecha pres.–interm. (pp)	Tendencia (pp/elección)	Volatilidad (pp)
[**PENDIENTE:** 2/pct]	[**PENDIENTE:** 2/media]	[**PENDIENTE:** 2/brecha]	[**PENDIENTE:** 2/tend]	[**PENDIENTE:** 2/vol]

[**PENDIENTE:** Quién es / cómo participa / qué lo distingue (6–9 líneas).]

5.4 Perfil 3: [PENDIENTE: nombre narrativo]

% de la lista nominal	Participación media (%)	Brecha pres.–interm. (pp)	Tendencia (pp/elección)	Volatilidad (pp)
[**PENDIENTE:** 3/pct]	[**PENDIENTE:** 3/media]	[**PENDIENTE:** 3/brecha]	[**PENDIENTE:** 3/tend]	[**PENDIENTE:** 3/vol]

[**PENDIENTE:** Quién es / cómo participa / qué lo distingue (6–9 líneas).]

5.5 Perfil 4: [PENDIENTE: nombre narrativo]

% de la lista nominal	Participación media (%)	Brecha pres.–interm. (pp)	Tendencia (pp/elección)	Volatilidad (pp)
[**PENDIENTE:** 4/pct]	[**PENDIENTE:** 4/media]	[**PENDIENTE:** 4/brecha]	[**PENDIENTE:** 4/tend]	[**PENDIENTE:** 4/vol]

[**PENDIENTE:** Quién es / cómo participa / qué lo distingue (6–9 líneas).]

Guía

Las fichas de los demás perfiles están en `outputs/figuras/ficha_perfil_N.png`; incluye solo las que quepan en el presupuesto de páginas. La tabla de trayectorias por perfil (`tabla_perfiles.tex`) sirve como resumen compacto si prefieres no insertar todas las fichas.

[**PENDIENTE:** tabla `tabla_perfiles.tex`; ejecuta generar_tablas_latex.py]

Tabla 2: Participación (%) por elección y peso en la lista nominal de cada perfil.

6. Estrategias diferenciadas de fomento a la participación

Guía

Una estrategia por perfil, *derivada de la evidencia*, no genérica. Estructura sugerida por fila: objetivo (qué comportamiento cambiar), mensaje (idea central, con tono adecuado al perfil), canal y momento (dónde y cuándo; p. ej. antes de una elección intermedia, donde el perfil cae), indicador de éxito (cómo se mide, p. ej. cerrar la brecha de X pp en la siguiente intermedia). Ejemplo de lógica: perfil con brecha presidencial–intermedia grande $\Rightarrow$ la estrategia debe explicar por qué las elecciones intermedias también importan y concentrarse en el periodo previo a

la siguiente elección federal intermedia (verifica el calendario electoral).

[**PENDIENTE:** 1–2 frases que expliquen el criterio general para pasar del perfil a la estrategia.]

Perfil	Objetivo	Mensaje	Canal y momento	Indicador
0 [**PENDIENTE:** nombre]	[**PENDIENTE:**]	[**PENDIENTE:**]	[**PENDIENTE:**]	[**PENDIENTE:**]
1 [**PENDIENTE:** nombre]	[**PENDIENTE:**]	[**PENDIENTE:**]	[**PENDIENTE:**]	[**PENDIENTE:**]
2 [**PENDIENTE:** nombre]	[**PENDIENTE:**]	[**PENDIENTE:**]	[**PENDIENTE:**]	[**PENDIENTE:**]
3 [**PENDIENTE:** nombre]	[**PENDIENTE:**]	[**PENDIENTE:**]	[**PENDIENTE:**]	[**PENDIENTE:**]
4 [**PENDIENTE:** nombre]	[**PENDIENTE:**]	[**PENDIENTE:**]	[**PENDIENTE:**]	[**PENDIENTE:**]

Tabla 3: Estrategias diferenciadas por perfil.

7. Limitaciones y consideraciones éticas

Guía

Lista breve y honesta; ya vienen las tres limitaciones estructurales. Agrega las propias de tu análisis (cobertura de datos, segmentos descartados, sensibilidad a parámetros).

- **Datos agregados y falacia ecológica:** los perfiles describen segmentos, no individuos (Sección 3.6).
- **Cohortes:** los grupos de edad no siguen a las mismas personas entre elecciones.
- **Asociación, no causalidad:** los perfiles describen patrones; las causas de la participación requieren otros diseños.
- **Uso responsable:** los perfiles deben orientar apoyo y comunicación, no estigmatizar territorios ni grupos.
- [**PENDIENTE:** Limitaciones propias: sensibilidad al k y a los umbrales, escolaridad no disponible, etc.]

8. Conclusiones y trabajo futuro

Guía

Tres o cuatro ideas: qué se encontró, qué debería hacer el INE primero, qué queda por mejorar (p. ej. incorporar indicadores socioeconómicos territoriales, evaluar las estrategias con pilotos). No introduzcas resultados nuevos.

[**PENDIENTE:** Conclusiones (6–8 líneas) y 1–2 líneas de trabajo futuro.]

Referencias

[1] Instituto Nacional Electoral. *Conteos Censales de Participación Ciudadana 2009–2024* (plataforma de datos abiertos). `https://ine.mx/transparencia/datos-abiertos/visualizacion-datos/conteos-censales-participacion/`

[2] Instituto Nacional Electoral. *Convocatoria Hackea la Participación: Datos que construyen democracia* (2026). `https://ine.mx/wp-content/uploads/2026/09/Convocatoria_Hackaton.pdf`

[3] Instituto Nacional Electoral (2024). *Documento rector para la integración de la base de datos censal de la participación ciudadana en el Proceso Electoral Federal 2023–2024* (INE/CCOE/023/2024).

[4] MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proc. 5th Berkeley Symposium*, 1, 281–297.

[5] Lloyd, S. (1982). Least squares quantization in PCM. *IEEE Trans. Information Theory*, 28(2), 129–137.

[6] Ward, J. H. (1963). Hierarchical grouping to optimize an objective function. *J. American Statistical Association*, 58(301), 236–244.

[7] Schwarz, G. (1978). Estimating the dimension of a model. *Annals of Statistics*, 6(2), 461–464.

[8] Rousseeuw, P. J. (1987). Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. *J. Computational and Applied Mathematics*, 20, 53–65.

[9] Caliński, T., Harabasz, J. (1974). A dendrite method for cluster analysis. *Communications in Statistics*, 3(1), 1–27.

[10] Davies, D. L., Bouldin, D. W. (1979). A cluster separation measure. *IEEE TPAMI*, 1(2), 224–227.

[11] Hubert, L., Arabie, P. (1985). Comparing partitions. *J. Classification*, 2, 193–218.

[12] Hennig, C. (2007). Cluster-wise assessment of cluster stability. *Computational Statistics & Data Analysis*, 52(1), 258–271.

[13] Robinson, W. S. (1950). Ecological correlations and the behavior of individuals. *American Sociological Review*, 15(3), 351–357.

[14] Pedregosa, F. et al. (2011). Scikit-learn: machine learning in Python. *J. Machine Learning Research*, 12, 2825–2830.

Lista de verificación antes de entregar

- 8 a 12 cuartillas con `\guiafalse`; PDF final; Arial/Calibri 11, interlineado 1.5.
- Entre 4 y 6 perfiles claramente diferenciados, con metodología de segmentación y estrategias por perfil.
- Cero textos en rojo [PENDIENTE]; nombres de perfiles definitivos; cifras coherentes con las tablas.
- Fichas de perfil (infografía/dashboard) en PDF/PNG de alta resolución, aparte de este documento.
- Solo datos agregados; aviso explícito de falacia ecológica; repositorio accesible.
- Entrega a más tardar el 31 de octubre de 2026, 23:59 h, junto con presentación (máx. 10 diapositivas), código, y las cartas de cesión de derechos y de decir verdad firmadas por todas las personas integrantes.