Perfiles de participación electoral en México

Datocracia | Documento técnico | Reto 1

Miguel Angel López Sánchez · Eric Diego Calderon Escutia · Ariana Tejeda Santiz

Maestría en el Posgrado en Ciencia e Ingeniería de la Computación

Universidad Nacional Autónoma de México · Tercer semestre

31 de octubre de 2026

Resumen

Datocracia identifica 6 perfiles de participación electoral a partir de los Conteos Censales de Participación Ciudadana del INE de 2009 a 2024. Se agrupan 12,000 segmentos de entidad, distrito de referencia, sexo y edad mediante K-means, utilizando participación media, brecha presidencial–intermedia, cambio reciente e irregularidad de trayectoria. La edad, el sexo y el territorio se emplean para caracterizar los grupos. La solución distingue baja participación persistente, sensibilidad al tipo de elección, irregularidad, descenso reciente, recuperación y participación alta sostenida. La silueta global es 0.238 y el ARI de estabilidad territorial es 0.698, por lo que los perfiles se interpretan como patrones descriptivos con solapamiento. Se proponen líneas institucionales de información, accesibilidad y evaluación del servicio, sin atribuirles efectos causales observados.

Palabras clave: participación electoral, perfiles ciudadanos, K-means, series temporales, CCPC.

1 Introducción

Un promedio electoral puede reunir segmentos que participan de manera distinta. Dos grupos con niveles históricos semejantes pueden responder de forma diferente a una elección presidencial, registrar cambios recientes opuestos o mostrar una trayectoria irregular. El reto consiste en reconocer esos contrastes y describir su composición poblacional y territorial sin confundir los registros agregados con el seguimiento de las mismas personas.

El objetivo es construir e interpretar 6 perfiles de participación a partir de las elecciones federales de 2009, 2012, 2015, 2018, 2021 y 2024. El proyecto corresponde al Reto 1 de la convocatoria del INE [1]. Su aportación es una representación interpretable de nivel, contexto electoral y evolución temporal, acompañada de una evaluación de separación y estabilidad que delimita la lectura de los resultados.

2 Antecedentes

El agrupamiento de series mediante características transforma cada trayectoria en indicadores comparables antes de aplicar un algoritmo de clasificación no supervisada. Wang, Smith e Hyndman [3] desarrollan este enfoque; Hyndman, Wang y Laptev [4] utilizan características para detectar series inusuales. Datocracia adapta esa representación a 6 observaciones electorales. Las fórmulas concretas son decisiones del proyecto y no se atribuyen literalmente a esos trabajos.

La silueta de Rousseeuw [5] permite estudiar cohesión y separación, mientras que la estabilidad por grupo aporta una perspectiva complementaria [6]. Un resultado de clustering debe interpretarse de acuerdo con su finalidad [7]. En este caso, interesa distinguir patrones electorales útiles para la descripción institucional, manteniendo visibles sus fronteras y limitaciones.

3 Conjunto de datos y preprocesamiento

Se utilizan los archivos agregados de CCPC del INE [2], con año, entidad, distrito, municipio, sección, tipo de sección, sexo, edad y los conteos de lista nominal (LN), personas que votaron (SV), personas que no votaron (NV) y participación no especificada (NS). La unidad final es entidad federativa × distrito federal de referencia × sexo × grupo de edad. La escolaridad no está disponible en las variables utilizadas. Los tipos de sección se agregan dentro de cada unidad.

La lectura por bloques reduce el consumo de memoria. Antes de sumar conteos, se excluyen valores numéricos nulos o no finitos, LN no positiva, conteos negativos, cantidades incompatibles con LN, incumplimiento de LN = SV + NV + NS, años ajenos a la serie y categorías inválidas. Cada registro recibe un primer motivo de exclusión. Municipio, sección y referencias de origen se conservan para el enlace territorial.

Las edades se agrupan cada 3 años desde 18–20 hasta 60–62; después se emplean 63–66, 67–70, 71–74, 75–79 y 80 o más, con límite operativo de 114 años. La ampliación de los últimos intervalos reduce la fragmentación de segmentos pequeños. Los distritos se reconstruyen mediante correspondencias de sección y municipio hacia un marco de referencia DERFE 2023. Se admiten enlaces aproximados, de modo que la comparabilidad distrital es analítica y no una equivalencia histórica exacta.

Los conteos se suman por segmento y elección antes de calcular $T_a = 100 \times SV_a/(LN_a - NS_a)$. NS no se clasifica como abstención. Un segmento requiere las 6 tasas observadas y un denominador LN − NS de al menos 30 en cada año; no se imputan tasas. Se conservan 12,000 de 12,098 segmentos del diagnóstico. Los 98 excluidos tienen cobertura incompleta y corresponden a la categoría no binaria, por lo que la solución incluida caracteriza hombres y mujeres.

4 Metodología de segmentación

4.1 Representación de la participación

Cada segmento se representa con 4 indicadores derivados exclusivamente de sus porcentajes electorales. La participación media es el promedio de las 6 tasas y describe el nivel histórico. La brecha presidencial–intermedia es el promedio de 2012, 2018 y 2024 menos el de 2009, 2015 y 2021; un valor positivo indica mayor participación en las primeras. Se expresan, respectivamente, en porcentaje y puntos porcentuales.

El cambio reciente promedia los cambios anuales de los últimos periodos comparables por tipo de elección:

$$\text{Cambio reciente} = [(T2021 - T2015) + (T2024 - T2018)] / 12$$

La irregularidad es la raíz del promedio de residuos cuadrados de una regresión de las 6 tasas sobre una constante, un indicador de jornada presidencial y el año centrado. Mide la desviación respecto de un patrón de nivel, diferencia entre tipos de elección y tendencia lineal común. Se expresa en puntos porcentuales; no es una estimación de incertidumbre estadística.

4.2 Escalado y ajuste

StandardScaler resta la media y divide entre la desviación estándar poblacional de cada indicador. El escalador se ajusta sin pesos. K-means utiliza pesos proporcionales a la raíz cuadrada del denominador medio del segmento, normalizados a media 1. Un soporte 100 veces mayor recibe 10 veces el peso, moderando la dominancia de segmentos grandes. La lista nominal y las variables sociodemográficas no se añaden como coordenadas de distancia.

Se fija k = 6 por el objetivo del proyecto, con 50 inicializaciones y semilla 42. Este valor no se presenta como un óptimo descubierto. La PCA es una proyección descriptiva y no sustituye las 4 entradas. Los indicadores se resumen por perfil con el peso del modelo; las trayectorias se calculan agregando SV y denominadores por elección. La LN media se reserva para describir composición y presencia territorial.

4.3 Evaluación

La separación se examina con silueta global e individual y la proporción de valores negativos. Para la estabilidad se realizan 20 submuestras sin reemplazo de 25 de las 32 entidades. En cada repetición se reajustan escalador y K-means y se predicen las asignaciones del universo completo. El ARI compara entre sí las particiones de las repeticiones; Jaccard mide la coincidencia de cada perfil completo con su grupo más semejante en cada repetición.

5 Resultados e interpretación

5.1 Panorama general

Los 12,000 segmentos corresponden a 32 entidades, 300 distritos de referencia y 20 grupos de edad. La lista nominal media (LN media) incluida suma 86.31 millones; no equivale a personas únicas ni a la lista nominal nacional de un solo año. Los perfiles reúnen entre 1,222 y 3,046 segmentos y representan entre 11.72 % y 22.51 % de esa LN media.

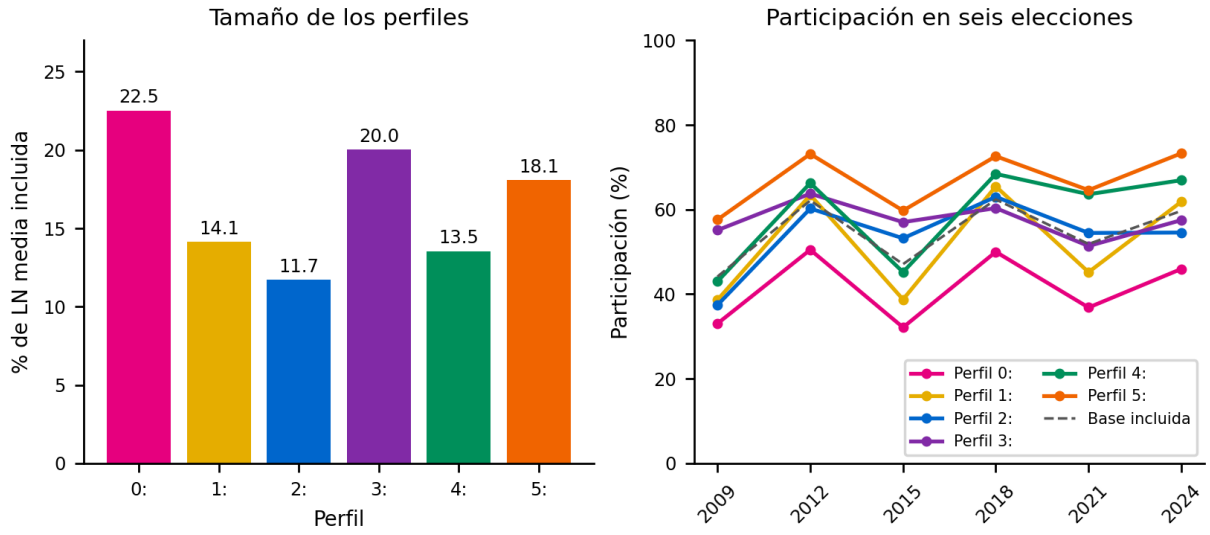


Figura 1. Composición de la base por perfil y participación en las 6 elecciones. La línea discontinua representa la base incluida. Fuente: elaboración propia con datos CCPC del INE, 2009–2024.

La participación agregada fue de 44.13 % en 2009, 62.12 % en 2012, 47.07 % en 2015, 62.37 % en 2018, 51.84 % en 2021 y 59.67 % en 2024. Todas las jornadas presidenciales superan a las intermedias. La media de cada perfil, sin embargo, no basta para distinguir sus cambios recientes ni su regularidad.

Perfil	Segmentos	LN media %	Media %	Brecha pp	Cambio pp/año	Irregularidad pp
0:	2,261	22.51	41.64	14.57	+0.08	3.00
1:	1,296	14.14	52.52	22.47	+0.21	2.69
2:	1,222	11.72	54.67	10.61	-0.70	6.72
3:	2,368	20.01	58.20	5.67	-0.73	2.16
4:	1,807	13.53	59.61	16.29	+1.34	5.31
5:	3,046	18.08	66.94	12.00	+0.47	2.32

Tabla 1. Tamaño e indicadores de los 6 perfiles. LN media expresa composición; los indicadores se resumen con la raíz del denominador medio. pp: puntos porcentuales.

La silueta exacta es 0.238; 362 segmentos, equivalentes a 3.02 %, tienen valores negativos. El ARI territorial medio es 0.698, con desviación estándar de 0.117. Existe diferenciación descriptiva, pero también solapamiento y sensibilidad al conjunto de entidades del ajuste. El perfil 2 tiene Jaccard medio de 0.897 y 10.15 % de siluetas negativas: la repetibilidad de un grupo no garantiza que todos sus casos estén claramente separados.

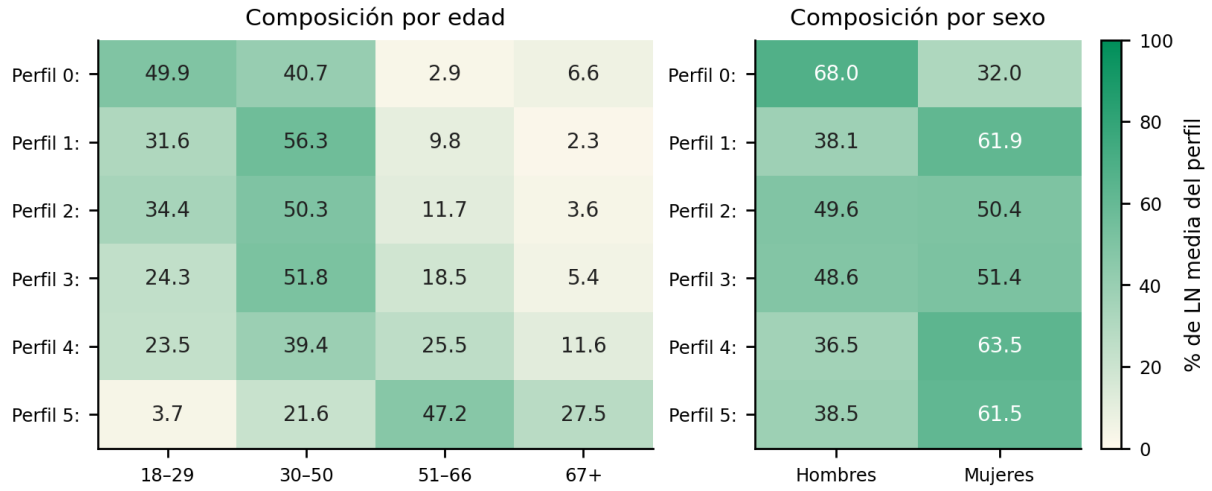


Figura 2. Composición de los perfiles por edad y sexo. Los valores representan porcentajes de LN media dentro de cada perfil, no tasas de participación.

5.2 Distribución territorial

Los mapas permiten comparar la presencia de cada perfil dentro de las bases estatales incluidas. La escala es común, de 0 % a 100 %, y el color conserva la identidad del perfil. Una presencia alta no implica que el estado aporte la mayor parte de ese grupo a escala nacional. La lectura territorial mantiene el carácter aproximado de las correspondencias distritales.

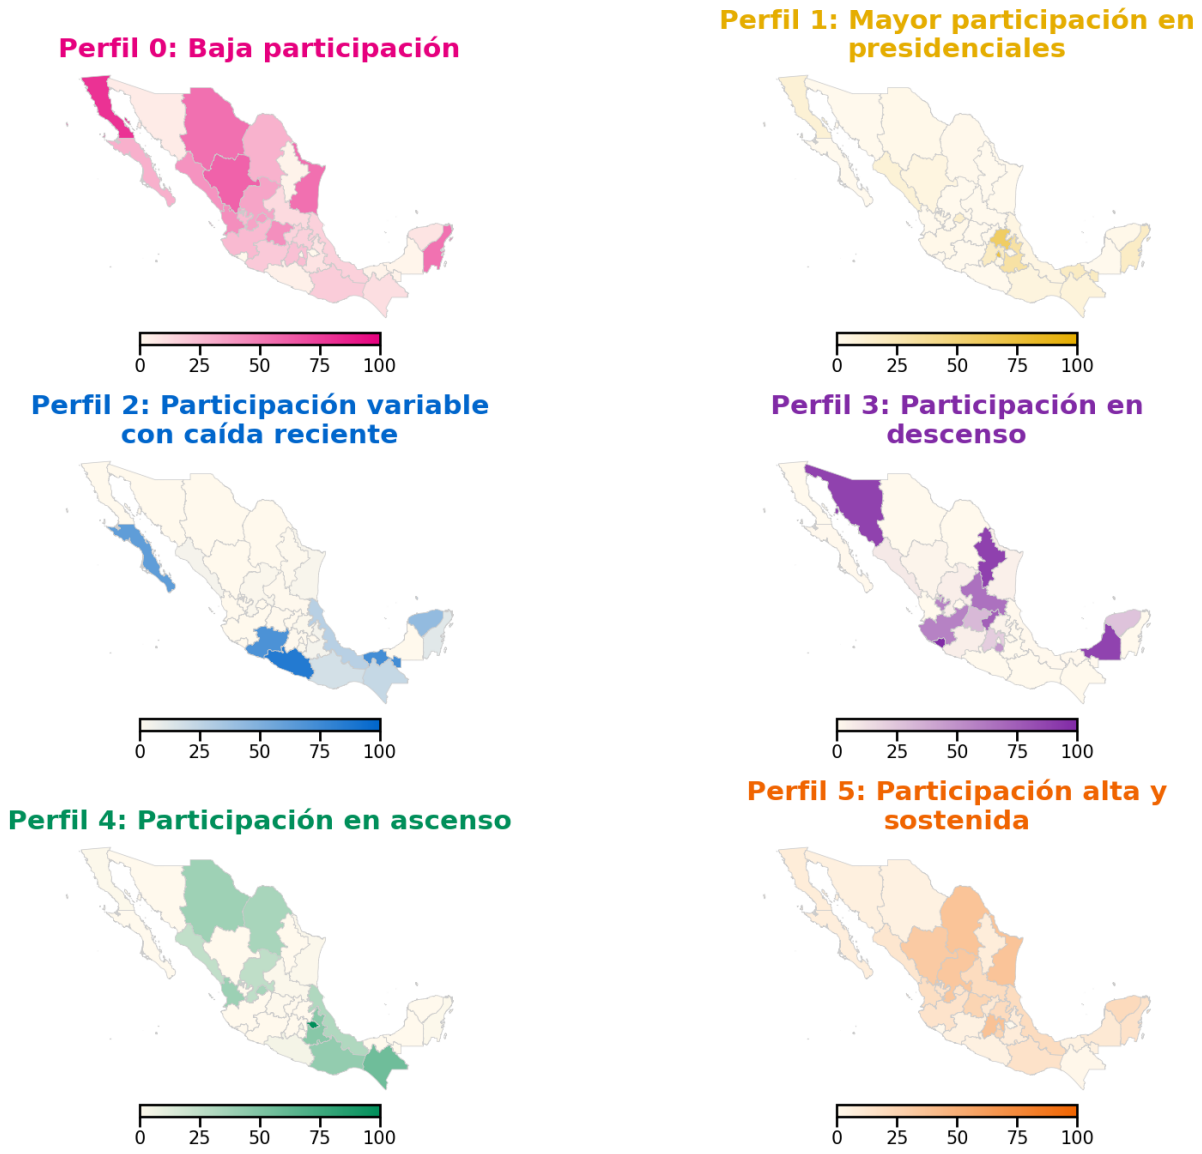


Figura 3. Presencia estatal de los 6 perfiles. Cada escala indica el porcentaje de LN media estatal incluida que pertenece al perfil. Fuente: CCPC, cartografía estatal del INEGI [8] y elaboración propia.

5.3 Perfil 0: Baja participación

Es el perfil con menor participación media, 41.64 %. Aunque participa más en las presidenciales que en las intermedias, se mantiene por debajo de los demás perfiles. El cambio reciente es de apenas +0.08 pp/año: hay poca mejora en conjunto. También presenta una participación menor que la referencia nacional de su misma edad y sexo.

Las edades de 18 a 29 años reúnen 49.90 % de su LN media y los hombres 67.97 %. En Baja California representa 79.74 % de la base estatal incluida. Estos datos ayudan a ubicar el patrón, pero no explican por qué ocurre. El nombre describe tasas bajas; no supone desinterés ni permite conocer las razones individuales para no votar.

5.4 Perfil 1: Mayor participación en presidenciales

La diferencia más clara está en el tipo de elección. La participación presidencial supera a la intermedia en 22.47 pp, la brecha más grande de los 6 perfiles. Por eso su media de 52.52 % no cuenta toda la historia: combina tasas relativamente altas en presidenciales con tasas bajas en intermedias. Su cambio reciente es pequeño frente a esa diferencia.

Las edades de 30 a 50 años representan 56.28 % de su LN media y las mujeres 61.91 %. Ciudad de México aporta 44.86 % del grupo. Al cambiar las entidades utilizadas para ajustar el modelo, su composición varía más que la de otros perfiles, con Jaccard de 0.690. El nombre indica cuándo participa más; no significa que participe únicamente en presidenciales.

5.5 Perfil 2: Participación variable con caída reciente

Este perfil combina mejoras anteriores con una caída reciente. El ejemplo más claro está en las presidenciales: su tasa agregada pasa de 62.98 % en 2018 a 54.54 % en 2024. La media es 54.67 %, el cambio reciente −0.70 pp/año y la irregularidad 6.72 pp, la mayor de los 6 perfiles. No disminuye durante todo el periodo: cambia de dirección entre etapas.

Destaca por su presencia en Guerrero, Tabasco y Michoacán, y tiene una composición por sexo equilibrada. Se diferencia del perfil 3 por sus variaciones más marcadas, no por una caída más intensa. El grupo se reproduce con frecuencia al repetir el ajuste, pero 10.15 % de sus segmentos tienen silueta negativa y podrían encajar mejor en otro perfil. Su descripción resume el patrón del conjunto, no una trayectoria idéntica en todos sus segmentos.

5.6 Perfil 3: Participación en descenso

La participación disminuye en las comparaciones recientes entre elecciones del mismo tipo. Su cambio es de −0.73 pp/año y su irregularidad es baja, 2.16 pp. Frente al perfil 2, el descenso sigue un patrón más regular. La brecha presidencial–intermedia, de 5.67 pp, es la menor de los 6 grupos: el tipo de elección marca menos diferencia en su participación.

Las edades de 30 a 50 años concentran 51.80 % de su LN media y la composición por sexo es cercana al equilibrio. Tiene una presencia elevada en Colima, Nuevo León y Sonora. Su participación media, 58.20 %, todavía supera a la de varios perfiles; el nombre señala que está bajando, no que sea la más baja. Tampoco implica que sean las mismas personas quienes dejaron de votar.

5.7 Perfil 4: Participación en ascenso

El aumento más claro aparece en las elecciones intermedias, sobre todo en 2021. Tiene el mayor cambio reciente de los 6 perfiles, +1.34 pp/año, y una participación media de 59.61 %. El ascenso no ocurre en todas las elecciones: la tasa presidencial de 2024 es algo menor que la de 2018. Su irregularidad de 5.31 pp refleja esas diferencias entre etapas.

Las mujeres representan 63.50 % de su LN media. El grupo incluye distintas edades y destaca en Tlaxcala, Chiapas y Puebla. Su Jaccard de 0.884 indica que el patrón se conserva bastante al repetir el ajuste con otras entidades. Los datos muestran una mejora reciente en conjunto, pero no permiten atribuirla a una campaña, programa o causa específica.

5.8 Perfil 5: Participación alta y sostenida

Se mantiene entre los grupos con mayor participación tanto en presidenciales como en intermedias. Tiene la media más alta, 66.94 %, una irregularidad baja de 2.32 pp y un cambio reciente de +0.47 pp/año. “Sostenida” significa que conserva un nivel comparativamente alto a lo largo del periodo, aunque sus tasas cambien entre elecciones.

Las edades de 51 años o más reúnen 74.66 % de su LN media y las mujeres 61.46 %. Su presencia territorial está más repartida que la de otros perfiles. Es el grupo con menor proporción de siluetas negativas, lo que facilita distinguirlo de los demás. Su participación alta no demuestra mayor calidad democrática ni permite afirmar que cada persona haya votado de manera constante.

6 Propuestas de fomento y aprovechamiento institucional

Los perfiles permiten organizar problemas de información y acceso que conviene estudiar. Las propuestas siguientes se plantean como servicios públicos abiertos a toda la ciudadanía y mejoras del servicio electoral. No son efectos demostrados por el clustering: su utilidad debe evaluarse mediante indicadores de operación, comprensión y acceso, con participación voluntaria y sin condicionar la atención a la pertenencia a un perfil.

6.1 Perfil 0: Baja participación

Orientación integral y reducción de barreras. La participación baja sin recuperación motiva revisar si la información sobre trámites, requisitos, fechas y ubicación de servicios resulta fácil de encontrar y comprender. Se propone integrar esa información en una guía pública breve, disponible en formatos digitales y presenciales, con un canal para resolver dudas procedimentales. La evaluación puede medir consultas resueltas, errores frecuentes y facilidad para completar la búsqueda de información.

6.2 Perfil 1: Mayor participación en presidenciales

Continuidad informativa entre tipos de elección. La diferencia entre presidenciales e intermedias plantea revisar la consistencia de la información institucional entre procesos. Se propone mantener un calendario público comparable que explique qué se elige, las atribuciones de los cargos, las fechas y los procedimientos de cada jornada. El indicador principal sería la comprensión de esas diferencias y la cobertura de información disponible, sin suponer que comprenderlas determina la decisión de participar.

6.3 Perfil 2: Participación variable con caída reciente

Información verificable ante cambios de contexto. La irregularidad recomienda revisar discontinuidades del servicio antes de atribuir el comportamiento a una sola causa. Un registro público de cambios de ubicación, reglas y canales de atención, acompañado de actualizaciones verificables y control de versiones, facilitaría la consulta. Pueden evaluarse la oportunidad de las correcciones, la proporción de información vigente y las dudas recurrentes, junto con estudios generales de barreras administrativas.

6.4 Perfil 3: Participación en descenso

Escucha sobre dificultades de acceso. El descenso reciente justifica investigar si existen problemas del servicio que no aparecen en los conteos. Se propone una consulta voluntaria y abierta sobre claridad de requisitos, disponibilidad de información, accesibilidad y dificultades de atención. Sus resultados servirían para priorizar correcciones administrativas. Conviene medir la resolución de incidencias y los cambios en la experiencia del servicio, sin atribuir las causas del descenso a respuestas aisladas.

6.5 Perfil 4: Participación en ascenso

Seguimiento de la recuperación y documentación de prácticas. La recuperación reciente ofrece una oportunidad para comparar cómo cambiaron los servicios y el contexto entre procesos. Se propone documentar prácticas generales de información y accesibilidad, distinguiendo su fecha, alcance y recursos, y contrastarlas con evidencia administrativa. La evaluación buscaría identificar prácticas replicables mediante pilotos de servicio y mediciones de comprensión, sin presentar la coincidencia temporal como prueba de eficacia.

6.6 Perfil 5: Participación alta y sostenida

Conservación de condiciones de acceso. La participación alta y sostenida aconseja preservar la continuidad del servicio y vigilar barreras que podrían pasar inadvertidas. Se propone revisar periódicamente la legibilidad de los materiales, la accesibilidad física y digital y la claridad de los canales de atención, con alternativas presenciales. La disponibilidad del servicio, la resolución de solicitudes y la satisfacción de las personas usuarias permitirían monitorear estas condiciones de manera general.

7 Discusión y conclusiones

La solución no se reduce a ordenar la participación de menor a mayor. La brecha distingue al perfil 1; la irregularidad separa al perfil 2 de trayectorias más regulares; y la dirección reciente diferencia al perfil 3 del 5. El perfil 4 concentra recuperación y oscilación, mientras el 0 mantiene un nivel bajo con poca mejoría. Los nombres son síntesis interpretativas del equipo y no categorías generadas automáticamente por el código.

La composición por edad explica parte de los contrastes, pero no los agota. Al estandarizarla, la distancia entre la mayor y menor tasa por perfil permanece entre 16.70 y 22.04 pp, con cobertura completa de edades. El sexo y el territorio caracterizan los resultados; no intervienen como coordenadas del ajuste. Las tasas describen segmentos sucesivos y no permiten separar efectos de edad, periodo y cohorte ni identificar causalidad.

La silueta de 0.238 y el ARI de 0.698 sitúan el resultado como una tipología descriptiva con fronteras permeables y estabilidad desigual. También limitan la extrapolación las correspondencias distritales aproximadas, el tratamiento de NS, la exclusión de series incompletas y la disponibilidad de solo 3 observaciones por tipo de elección. La utilidad institucional reside en organizar preguntas y comparaciones, no en asignar atributos políticos a individuos o prometer aumentos de participación.

El proyecto entrega una metodología reproducible, 6 perfiles nombrados y caracterizados y propuestas de mejora del acceso y la información. La aplicación institucional requiere contrastar los patrones con conocimiento operativo y evaluar las acciones de servicio antes de atribuirles resultados. El producto permite comunicar diferencias observadas y orientar nuevas preguntas de investigación sin ocultar la incertidumbre del agrupamiento.

Referencias

[1] Instituto Nacional Electoral. Convocatoria Hackea la participación Datos que construyen democracia, 2026. https://ine.mx/wp-content/uploads/2026/09/Convocatoria_Hackaton-1.pdf

[2] Instituto Nacional Electoral. Conteos Censales de Participación Ciudadana 2009–2024 y diccionarios de datos. https://ine.mx/transparencia/datos-abiertos/visualizacion-datos/conteos-censales-participacion/

[3] X. Wang, K. Smith y R. J. Hyndman. “Characteristic-based clustering for time series data”. Data Mining and Knowledge Discovery, 13, 335–364, 2006. doi: 10.1007/s10618-005-0039-x.

[4] R. J. Hyndman, E. Wang y N. Laptev. “Large-scale unusual time series detection”. IEEE ICDMW, 1616–1619, 2015. doi: 10.1109/ICDMW.2015.104.

[5] P. J. Rousseeuw. “Silhouettes: A graphical aid to the interpretation and validation of cluster analysis”. Journal of Computational and Applied Mathematics, 20, 53–65, 1987. doi: 10.1016/0377-0427(87)90125-7.

[6] C. Hennig. “Cluster-wise assessment of cluster stability”. Computational Statistics & Data Analysis, 52, 258–271, 2007. doi: 10.1016/j.csda.2006.11.025.

[7] U. von Luxburg, R. C. Williamson e I. Guyon. “Clustering: Science or Art?”. Proceedings of Machine Learning Research, 27, 65–79, 2012. https://proceedings.mlr.press/v27/luxburg12a.html

[8] Instituto Nacional de Estadística y Geografía. Cartografía de áreas geoestadísticas estatales, servicio web del Catálogo Único de Claves de Áreas Geoestadísticas Estatales, Municipales y Localidades. https://gaia.inegi.org.mx/wscatgeo/v2/geo/mgee/